NYUv2 Semantic Segmentation CLIP-ViT + Late Fusion Implementation on Apple M1

— M1/Apple環境における CLIP ViT + Late Fusion 実装 —

※ 本プロジェクトは個人開発ポートフォリオとして実装したものである。

※ 本プロジェクトでは講座の最終課題で使用されたデータセットを実験用に流用しているが、コミュニティ規約によりデータセット自体は公開対象としない。そのため完全な再現は難しい可能性があるが、実験設定・モデル構成・学習条件については本レポート内で可能な限り詳細に記述した。

著　者:菅　良平

所　属:ZEN大学

作成日:2026年3月

要約表

項目	内容
タスク	RGB-D Semantic Segmentation
データセット	NYUv2
モ デ ル	CLIP ViT + Depth CNN + Late Fusion
損失関数	Focal Loss + Dice Loss
ベースライン	DeepLabV3+
結果	mIoU 0.6144
到達スコア	課題ベースライン:0.38(比 +0.23) / 前回ベースライン(Deeplab V3+):0.51-0.53(比 +0.08)
環境	Apple M1 / 16GB RAM

プロジェクト概要

サンプル数	NYUv2（Train: 695 / Val: 100 / Test: 654） （※正解ラベル非公開/評価サイト投稿用のため）

入/出力	RGB画像＋深度マップ（カメラからの距離）→ 13クラス分類ラベル
主要評価指標	mean Intersection over Union（mIoU）
最終到達スコア	**mIoU 0.6144** (ベースライン:0.38比で約59%向上)

概要：背景および課題（DeepLabV3+）

前回の実装においては、CNNベースのDeepLabV3+を採用し、NYUv2データセットを用いた訓練・検証を行ったが、以下の課題が残った。

- 深度情報の活用不足: 前回試行したEarly Fusionでは、入力段階でRGBと深度情報を結合させていた。しかし、直感的には画像の重なりによって異なる性質のデータ（輝度と距離）が干渉し、本来抽出されるべき特徴自体が分散・ノイズ化して捉えづらくなるというデメリットを確認した。結果として深度情報が単なる補助データに留まり、幾何学的な構造的特徴を抽出できず、汎化性能向上に寄与できなかったと考えた。
- 計算リソースの制約: CNNだけでは畳み込み層の構造上、広域的な特徴抽出を試みると演算量が指数関数的に増加する。そこで本実装では「意味的抽出（広域的な特徴把握）」を計算効率の良いTransformer（ViT）に任せるアーキテクチャに変更した。一方、深度情報の処理は複雑な質感などの余分な特徴の抽出が不要となり境界抽出が主目的になるため、軽量なCNNで十分対応可能と判断した。ViTとCNNを組み合わせた構成は計算量が増えるが役割分離による計算効率化によりM1環境での実用的な学習・推論を可能にした。
- * 空間解像度の維持: 従来構成では境界線の抽出精度が不足していた。本課題に対し意味的（ViT）と幾何的（CNN）を独立したストリームで捉え特徴を最後に結合するLate Fusionへの刷新、入力解像度の段階的な変更によって、特徴をストリーム毎に効率的かつ鮮明に抽出するアプローチが必要となった。

計算リソースと処理効率の比較

MODEL	GPU/Device	所要時間 (1EPOCH)	メモリ使用量
U-Net	T4/L4 GPU	約1分	15GB(BS:16)
DeepLabV3 Plus	T4/L4 GPU	約2分30秒	15GB(BS:16)
ViT + U-Net	**M1/Apple**	**約 3～9 分**	**16GB(BS:8/16)**

期間

日付	段階（フェーズ）	完了タスク	達成成果 / 到達スコア
2月23日 - 2月28日	ベース開発	データ分割、ViT/U-Netモデル設計、Late Fusion基礎設計、MLX/PyTorch環境構築	訓練準備完了
3月1日 - 3月6日	訓練・調整	ハイパラ（LR, 重み減衰）最適化、データ拡張・Loss関数実装、精度検証	[目標]前回スコアより汎化性能向上 mIoU:**0.6144**(前回比：**+7～9%**向上)
3月7日 - 3月8日	解析・整理	測定時バグの特定・修正、Visualizer / Log クラスのリファクタリング	リファクタリング（計測精度の信頼性担保）/コードの再利用性向上
3月9日 - 3月15日	公開準備～公開	ドキュメント整備・動作最終確認・GitHub公開（予定含む）	外部公開（ポートフォリオ）

提案手法：**M1**環境に最適化したアーキテクチャ

本実装はM1 Mac（16GB）という一般的な環境での 動作を前提に設計しており、特別な計算リソースなしに再現可能である。

1. アーキテクチャの刷新

   CNNベースからの脱却を図り、広域的な意味抽出に優れた事前学習済みViT（OpenAI CLIP）と
   深度特徴抽出に特化した軽量CNNを組み合わせたバックボーンを採用した。

2. マルチモーダル統合（Late Fusion）

   深度情報を補助データではなく独立したモダリティとして扱い、
   専用のU-Net（ResNet）エンコーダで幾何学的特徴を 抽出する。
   デコーダ側でViTの意味特徴と統合することで、意味抽出をViTに、
   幾何学的構造把握をU-Netに分離し精度向上を図った。

3. 差分学習率による最適化

   AdamWの差分学習率を採用し、CLIP-ViTの事前学習済み重みを保護しながらU-Net側を
   積極的に学習させることで、学習の早期収束と汎化性能向上を実現した。
   前回実装（DeepLabV3+）においても同手法の適用により数%の精度向上を確認しており、
   本実装でも同様の効果が期待できると考え採用した。

4. 複合損失関数と入力解像度の引き上げ

   クラス不均衡と境界精度の課題に対し、FocalLoss+DiceLossの複合損失関数を採用した。
   また、入力解像度を224→336→448に引き上げることで、小物クラスの画素特徴量が潰れることを
   抑制し、FocalLossによる難サンプル認識精度が向上した。
   この効果は全体mIoUおよびクラス別mIoUの改善として確認された。

※ 本アーキテクチャは、ViTと深度エンコーダの統合という設計を独自に検討・実装した結果、TransU-Net[1]・DPT[2]・FuseNet[7]の設計思想と共通する構造に至った。

前処理およびデータセット

本開発ではNYUv2 Datasetsを用い、室内環境のセマンティックセグメンテーションに取り組んだ。

項目	内容	目的

ホールドアウト分割	Train: **695** / Val: **100**	100 Sampleを未知データとして訓練データから隔離し、データリークを防止。
評価データ	Test : 654 スコア算出不可(1*)	訓練データから切り出した検証用データ**mIoU**を主指標に採用。
評価モード	model.eval() / torch.no_grad()	検証フェーズにおける勾配計算の停止と、推論用動作（Dropoutの無効化等）の徹底。

1* 正解ラベルが非公開のテストデータであるため、スコア評価不可。

システムおよびモデル構成

計算リソースに**Apple M1 (16GB RAM)** を使用し、**PyTorch (MPS)** によってモデル構築した。

入力解像度: 224×224 / 336×336 / 448×448

モデルアーキテクチャ（後期結合モデル / **Late Fusion**）

コンポーネント	実装・ベースモデル	主要な役割・特徴	最適化の工夫
RGBエンコーダ	**OpenAI CLIP (ViT)**	広域的な意味的特徴（Semantic）の抽出。物体カテゴリや質感の把握。	**L2**正則化と学習率の個別調整を行い、U-Net側との学習速度（歩幅）を同期。
深度エンコーダ	**Custom ResNet-based**	距離情報に基づく幾何学的特徴（Geometric）の抽出。物体の形状やエッジの把握。	軽量な独自構成を採用し、M1環境での演算コストを削減しつつ幾何情報に特化。
Late Fusion部	**U-Net Decoder**	ViTの意味的特徴とU-Netの幾何的特徴を結合、解像度を復元し最終出力を生成。	**512ch**の結合特徴量を256ch→128chへと段階的に集約し、13クラスへ投影。

アーキテクチャ図（Figure 1）

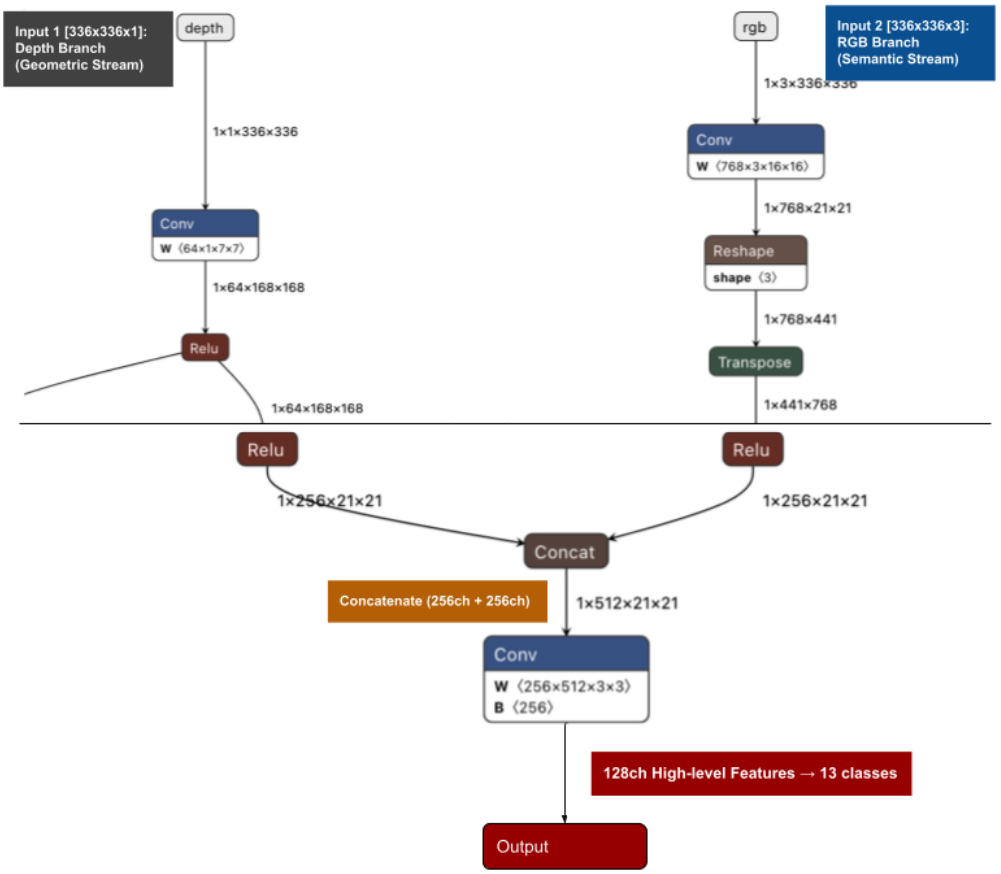

Figure 1: Late Fusion Model アーキテクチャ.

本モデルは幾何ストリーム（入力1: $336 \times 336 \times 1 : Depth$ ）と意味的ストリーム（入力2: $336 \times 336 \times 3 : RGB$ ）を統合する構成となっている。
特徴量の抽出には、それぞれResNet-18ベースのエンコーダ と 学習済みViT（Vision Transformer）を使用している。

両ストリームから抽出された特徴量（ 21×21 ）は、結合レイヤー（512チャネル）で統合される前に、同一の解像度へアップサンプリングされる。最終的な出力層では、128チャネルの高次元特徴表現を用いることで、全13クラスに対するセマンティックセグメンテーションを提供する。
本図は入力解像度336×336時のアーキテクチャを示す。最終的な訓練では448×448を採用した。

推論・学習パフォーマンス評価（M1/Apple）

項目	設定・条件	測定値 / パフォーマンス
平均推論時間	入力：336 × 336 （448 × 448）	**125.99 ms** **(248.04 ms)**
スループット **(FPS)**	入力：336 × 336 （448 × 448）	**7.94 FPS** **(4.03 FPS)**
学習効率 **(1 epoch)**	低解像度 (224 × 224) 高解像度 (336 × 336) 高解像度 (448 × 448)	約 3 ～ 4 分 約 6 ～ 7 分 約 8 ～ 9 分

- エンコーダの最適化: 結合エンコーダ（U-Net Based）を独自構成で実装し、演算コストを削減し幾何学特徴の学習に集中することで精度に貢献する工夫を行った。
- PyTorch の MPS（Metal Performance Shaders）バックエンドを利用し、M1 チップの GPUリソースを引き出すことが可能である。

訓練結果と定量/定性的評価

訓練時はデータ拡張（回転20度・ランダムクロップ スケール比率0.5〜1.0）およびDropoutが有効であるため、検証時との条件差が生じる。これは意図的な設計によるものであり、検証mIoU 0.57を記録し、一定の汎化性能を確保した。M1 Mac・695枚という制約環境下において、データ拡張による訓練/検証の条件差（約0.11〜0.16）はセグメンテーションタスクの誤差範囲内であり、予測画像においても大領域クラスの分類は概ね正確に行われていることからも、汎化性能として妥当であると判断した。訓練mIoU 0.78との差はこの条件差に起因するものであり、過学習ではないと考えた。

損失関数の選定と効果(Focal Loss + Dice Loss)

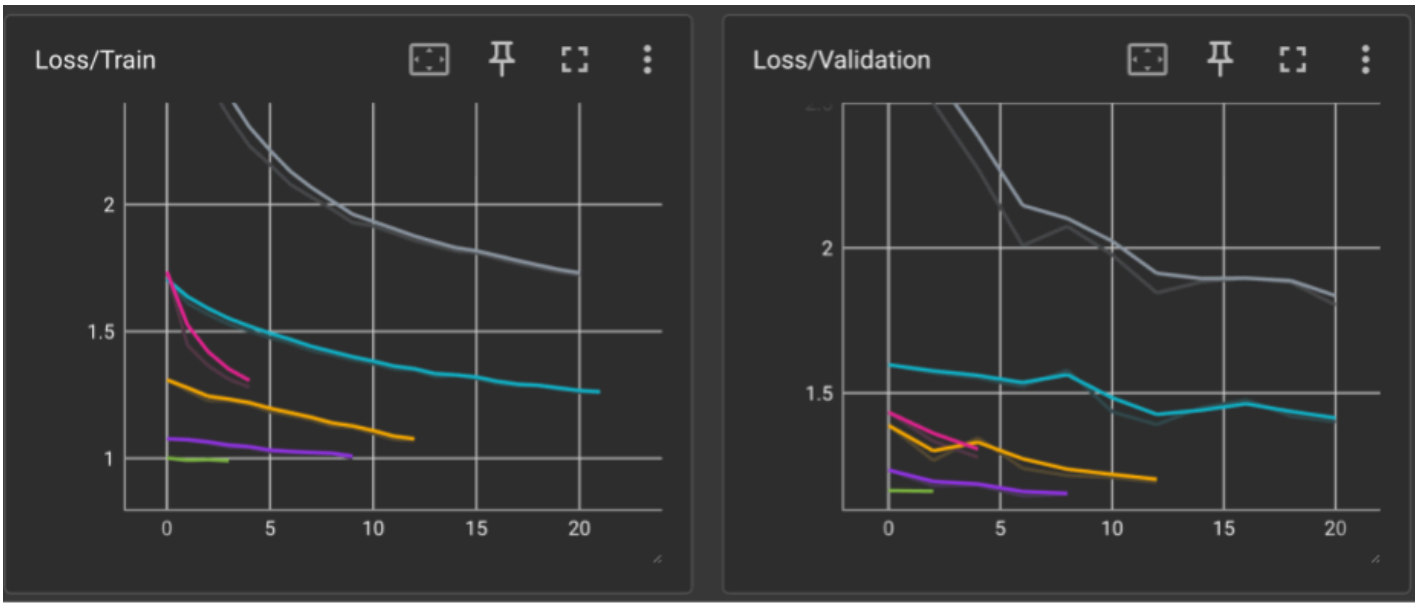

CrossEntropyLossでは大まかな形を捉えられるが、セグメンテーションタスクで求められる境界線と物体検出のバランスが取れないため、FocalLoss + DiceLossを採用した。

クラス不均衡対策

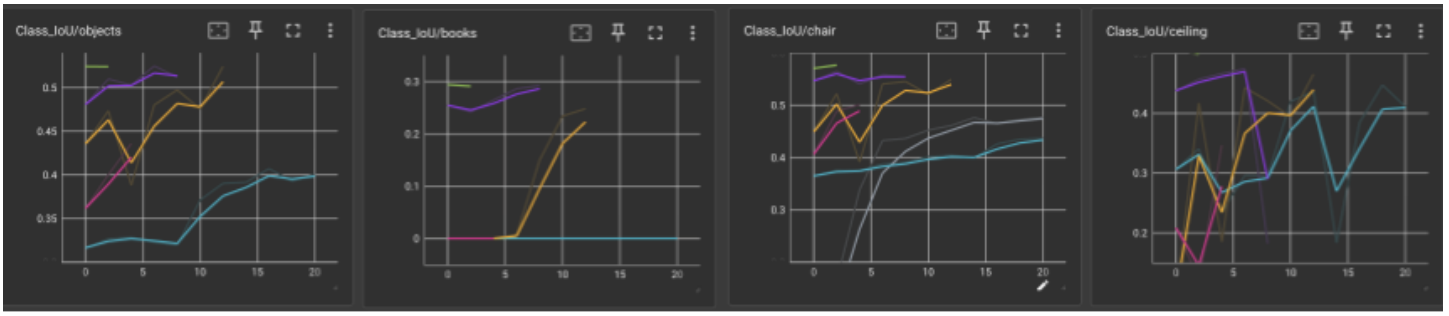

上図: 入力解像度336/下図: 入力解像度448

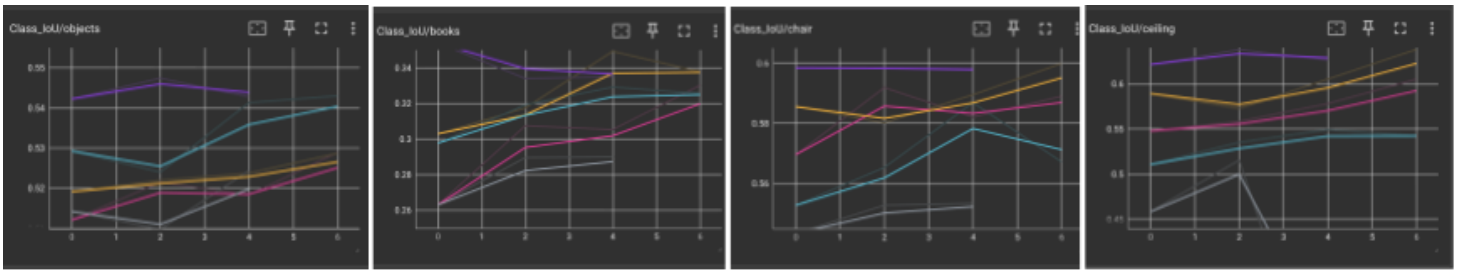

FocalLoss[6]はクラス不均衡（小物クラスなど難しいサンプル）への対応に優れ、DiceLossは境界線形状と物体領域の精度向上に寄与する。両者の組み合わせにより、U-Netの境界線検出をより強く反映させる重み付け（0.8）を設定した。また、入力解像度を336/448へ引き上げることで計算量増加がありメモリ不足にもなるが、境界線検出精度と小クラスの改善効果がクラス別IoU比較表において確認された。

予測画像の定性的分析

定性的なGT画像と予測画像の比較では、床・壁・Bedなどの大領域クラスの位置関係が正解ラベルとほぼ一致している一方、椅子の脚などの細部や小物クラスの境界線精度に課題が残る。解像度を段階的に引き上げることで、低解像度時に潰れていた領域においてもデコーダが境界線を学習し直し、クラス不均衡の影響を一定程度是正できたように見える。一方で、解像度向上に伴う過学習の兆候やノイズ除去の課題が残った。（上記画像は入力解像度：448×448）

mIoU測定値（※ mIoU評価系において下記数値を達成）

指標	値	指標	値
mIoU(訓練)	0.78	mIoU（検証）	**0.6144**
ベースライン (DeepLabV3+)	0.532	改善幅（検証比）	+0.082

クラス別 IoU 比較表（解像度別・検証クラス別 IoU 比較 [224/336/448]）

※ クラス名はNYUv2の13クラスを参考に独自定義したものであり、公式マッピングとの完全な一致は未検証です。
予測画像との目視確認により大きな乖離はないと判断していますが、厳密な対応は保証されません。

※ 差分はIoUスコアの絶対差（ポイント差）を示す。336→448の差分のみ記載（解像度448の追加実験による改善効果を示す）。

Class ID	クラス名	224（検証）	336（検証）	448（検証）	IoU差 (336→448)
0	bed	0.759	0.787	0.800	+0.013

1	books	0.245	0.291	0.335	+0.044
2	ceiling	0.496	0.495	0.626	+0.131
3	chair	0.521	0.570	0.598	+0.028
4	floor	0.830	0.869	0.866	-0.003
5	furniture	0.563	0.599	0.597	-0.002
6	objects	0.473	0.522	0.543	+0.021
7	picture	0.435	0.462	0.543	+0.081
8	sofa	0.421	0.386	0.407	+0.021
9	table	0.413	0.489	0.535	+0.046
10	tv	0.567	0.564	0.694	+0.130
11	wall	0.610	0.690	0.715	+0.025
12	window	0.577	0.642	0.729	+0.087
全体	mIoU	0.531	0.567	0.614	+0.047

今後の展望と課題

精度向上に向けた課題

- Boundary Lossの導入（境界線評価の厳密化）

考察

特徴量統合に関する考察

画像は一見すると単なる数値の集合に過ぎない。しかし、本実装のRGBストリーム（ViT）は、事前学習によって得たドメイン知識を用いることで、この画素の分散から「意味的な特徴（例：椅子や壁）」を抽出・解釈していると考えた。

1. 分散の意味化: 単なる色の変化（分散）を「物体の存在」としてRGBストリーム（ViT）が読み解く際、その「解像度」が不足していれば、分散はノイズへと埋没し、クラス不均衡の中で対象は潰れてしまう。
2. 幾何学的制約との統合: 一方で深度情報が持つ「幾何学的な分散（距離の変動）」は、幾何ストリーム（CNN/U-Net）によって「境界線」として抽出される。これら「意味」と「幾何」という異なる性質の分散をU-Netデコーダで結合させることで、高精度なセグメンテーションが可能となる。

結論として、本課題は「データの分散を、ドメイン知識を用いていかに正しく意味へと変換するか」というリソース制約下での実装例として有用な知見が得られた。

追加実験：高解像度化とストリーム凍結

当初、入力解像度448pxへの拡張は計算資源の指数関数的な増加に伴うメモリ不足（カーネルパニック）により、現環境の物理的限界として断念していた 。しかし、さらなる精度向上のため、以下の「ストリーム凍結」による最適化と追加訓練を実施した。

1. 巨大なバックボーンであるRGBストリーム (ViT) をあえて凍結 (Freeze) し、勾配計算をU-Netデコーダー/Late Fusion層に限定した。これによりVRAM消費を抑制でき、1 Epochあたりの学習時間を約13分から約9分へ**約37%**短縮することができた。
2. 凍結によってメモリ余力が生まれ、データセットのバッチサイズを4→8に拡大し訓練の安定化ができた。訓練の安定性とメモリー抑制を行いながら、モデルの汎化性能の収束を図った。

以上の計算資源の制約下でのモデル訓練によって、解像度向上と学習の安定性を両立した結果、深層学習コミュニティ講座のベースライン（mIoU: 0.38）/前回モデル訓練ベースライン(mIoU:0.51-0.53)をそれぞれ上回る **mIoU: 0.6144** を達成することができた。（※正解ラベル非公開のテストデータではなく、現環境の検証データによる予測値）

本実装における **mIoU 0.6144** は、限られた計算リソースを解像度・バッチサイズ・モデル複雑度の間のバランスを調整した結果として得られたものである。また、M1という一般的な環境で再現可能であることから今後の個人開発でも応用可能な実装例になった。

参考文献（References）

[1] Chen, J., et al. (2021). "TransU-Net: Transformers Make Strong Encoders for Medical Image Segmentation." *arXiv preprint arXiv:2102.04306*.

[2] Ranftl, R., et al. (2021). "Vision Transformers for Dense Prediction." *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 12179-12188.

[3] Radford, A., et al. (2021). "Learning Transferable Visual Models from Natural Language Supervision." *International Conference on Machine Learning (ICML)*, PMLR 139:8748-8763.

[4] Silberman, N., et al. (2012). "Indoor Segmentation and Support Inference from RGBD Images." *European Conference on Computer Vision (ECCV)*, Springer, Berlin, Heidelberg, pp. 746-760.

[5] Chen, L. C., et al. (2018). "Encoder-Decoder with Atrous Separable Convolution for Semantic Segmentation." *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 801-818.

[6] Lin, T. Y., et al. (2017). "Focal Loss for Dense Object Detection." *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 2980-2988.

[7] Hazirbas, C., et al. (2016). "FuseNet: Incorporating Depth into Semantic Segmentation via Fusion-based CNN Architecture." *Asian Conference on Computer Vision (ACCV)*, Springer, Cham, pp. 213-228.

[8] PyTorch Documentation. "Introducing Accelerated PyTorch Training on Mac." *PyTorch Blog (2022)*. Available at: https://pytorch.org/blog/introducing-accelerated-pytorch-training-on-mac/ (Accessed: 2026-03-10).

[9] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. Proceedings of the International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI), 2015. *arXiv preprint arXiv:*1505.04597.

[10] Gupta, S., Girshick, R., Arbelaez, P., & Malik, J. (2014). Learning Rich Features from RGB-D Images for Object Detection and Segmentation. Proceedings of the European Conference on Computer Vision (ECCV), 2014. *arXiv preprint arXiv:*1407.5736.

Reproducibility: Code and training scripts will be released on GitHub to ensure reproducibility.